

2209/A

ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEK
PROGRAMI

SONUÇ RAPORU

PROJE BAŞLIĞI: **Diyabetik Retinopati Evrelemesi için Derin
Öğrenme ve Ensemble Tabanlı Otomatik Teşhis Sistemi**

PROJE YÜRÜTÜCÜSÜNÜN ADI: **ZAHRA ESPARGHAMI**

DANIŞMANININ ADI: **PROF. DR. ÖZGÜR KORAY ŞAHİNGÖZ**

GENEL BİLGİLER

PROJENİN KONUSU	retina fundus görüntülerinden diyabetik retinopati (DR) evrelerinin derin öğrenme yöntemleri kullanılarak otomatik olarak sınıflandırılmasını amaçlamaktadır.
PROJE YÜRÜTÜCÜSÜNÜN ADI	ZAHRA ESPARGHAMI
DANIŞMANIN ADI	PROF. DR.ÖZGÜR KORAY ŞAHİNGÖZ
PROJE BAŞLANGIÇ VE BİTİŞ TARİHLERİ	1/05/2025 – 31/03/2026

1.Giriş

Diyabetik retinopati (DR), diyabet hastalığının retina üzerindeki mikrovasküler etkilerinden kaynaklanan, ilerleyici ve tedavi edilmediği takdirde kalıcı görme kaybına yol açabilen ciddi bir göz hastalığıdır[i]. Dünya genelinde diyabet prevalansının artmasıyla birlikte, diyabetik retinopati vakalarının sayısı da hızla artmakta ve bu durum hastalığı önemli bir halk sağlığı problemi haline getirmektedir. Özellikle erken evrelerde belirti göstermemesi ve hastaların çoğunlukla ileri evrelerde tanı alması, düzenli tarama sistemlerinin önemini artırmaktadır.

Geleneksel diyabetik retinopati tanısı, retina fundus görüntülerinin uzman hekimler tarafından manuel olarak incelenmesine dayanmaktadır. Ancak bu süreç; hem zaman alıcı olması hem de uzmanlar arasında yorum farklılıkları bulunabilmesi nedeniyle geniş ölçekli tarama programlarında sınırlı kalmaktadır. Ayrıca artan hasta yükü, özellikle gelişmekte olan ülkelerde yeterli sayıda uzman bulunmaması gibi problemler, otomatik ve güvenilir tanı sistemlerine olan ihtiyacı daha da belirgin hale getirmektedir.

Son yıllarda derin öğrenme yöntemleri, özellikle evrişimli sinir ağları (CNN) ve transformer tabanlı mimariler, medikal görüntü analizi alanında önemli başarılar elde etmiştir. Bu yöntemler, insan müdahalesine ihtiyaç duymadan görüntülerden anlamlı özellikleri otomatik olarak öğrenebilmekte ve yüksek doğrulukta sınıflandırma yapabilmektedir. Diyabetik retinopati tespiti de bu alanda en yoğun çalışılan problemlerden biri haline gelmiştir.

Bu proje kapsamında, diyabetik retinopati evrelerini otomatik olarak belirleyebilen, yüksek doğruluk ve genelleme yeteneğine sahip bir derin öğrenme sistemi geliştirilmiştir. Çalışmada Kaggle platformunda yer alan **Eyepacs veri seti**[ii] kullanılmış ve bu veri seti üzerinde kapsamlı bir ön işleme, veri artırma ve modelleme süreci yürütülmüştür. Veri setinin doğası gereği ciddi bir sınıf dengesizliği içerdiği gözlemlenmiş ve bu problem, proje kapsamında geliştirilen pipeline içerisinde özel olarak ele alınmıştır.

Proje sürecinde, klasik yaklaşımlardan başlayarak aşamalı bir model geliştirme stratejisi izlenmiştir. İlk aşamada ResNet50[iii], DenseNet[iv], InceptionV3[v] ve Xception[vii] gibi literatürde yaygın kullanılan CNN tabanlı mimariler ile temel performans analizi gerçekleştirilmiştir. Bu modeller, problemi anlamak ve baseline performans elde etmek amacıyla kullanılmıştır. Ancak elde edilen sonuçların hedeflenen doğruluk seviyesinin altında kalması, daha gelişmiş yöntemlerin uygulanmasını gerekli kılmıştır.

İkinci aşamada, transformer tabanlı Swin-Tiny modeli ve EfficientNet-B3 gibi daha modern mimariler kullanılarak performans artırılmaya çalışılmıştır. Bu modeller, klasik CNN mimarilerine göre daha yüksek temsil gücüne sahip olmalarına rağmen, veri dengesizliği ve sınıflar arası benzerlik gibi zorluklar nedeniyle istenilen performans seviyesine tek başına ulaşamamıştır. Bu durum, model performansını artırmak için yalnızca mimari değişimin yeterli olmadığını, aynı zamanda veri işleme ve öğrenme stratejilerinin de iyileştirilmesi gerektiğini göstermiştir.

Bu doğrultuda, projenin en kritik aşamasını oluşturan üçüncü fazda, kapsamlı bir veri artırma ve eğitim pipeline'ı geliştirilmiştir. Bu pipeline içerisinde retina görüntülerine özel augmentasyon teknikleri (CLAHE, gamma düzeltme, gürültü ekleme, rastgele kırpmaya vb.) uygulanmış, ayrıca sınıf dengesizliğini gidermek amacıyla **class-balanced focal loss**, **weighted sampling** ve **mixup** gibi ileri seviye yöntemler entegre edilmiştir. Bu sayede modelin özellikle nadir görülen ileri evre sınıfları daha iyi öğrenmesi sağlanmıştır.

Model performansını daha da artırmak amacıyla, projede çoklu model birleştirme (ensemble) yaklaşımı benimsenmiştir. Bu kapsamda ConvNeXt-Small, EfficientNetV2-S, EfficientNet-B3 ve Swin-Tiny modellerinin çıktıları belirli ağırlıklar ile birleştirilmiş ve elde edilen olasılık değerleri üzerinde **ordinal threshold optimizasyonu** uygulanmıştır. Bu yaklaşım, diyabetik retinopatinin doğası gereği sıralı (ordinal) bir problem olması dikkate alınarak tasarlanmıştır ve klasik argmax sınıflandırma yöntemlerine göre daha yüksek performans sağlamıştır.

Geliştirilen bu çok aşamalı sistem sonucunda, modelin doğrulama veri seti üzerinde **QWK $\approx$ 0.93** seviyesine ulaştığı gözlemlenmiştir. Bu değer, literatürde bildirilen birçok çalışmayla karşılaştırılabilir düzeyde olup, projenin hem metodolojik hem de uygulama açısından başarılı olduğunu göstermektedir.

Sonuç olarak bu çalışma, diyabetik retinopati evrelemesi problemine yalnızca model mimarisi üzerinden değil; veri işleme, kayıp fonksiyonu tasarımı, eğitim stratejileri ve ensemble yöntemleri gibi çok boyutlu bir yaklaşımla çözüm sunmaktadır. Geliştirilen sistem, klinik karar destek uygulamalarına entegre edilebilecek potansiyele sahip olup, erken teşhis süreçlerini hızlandırarak sağlık hizmetlerine önemli katkılar sağlayabilecek niteliktedir.

2.Rapor dönemlerinde yapılan çalışmalar

2.1 Veri Seti Oluşturma ve Ön İşleme Süreci


Bu çalışma kapsamında diyabetik retinopati evrelemesi problemi için Kaggle platformunda yer alan **Diabetic Retinopathy Detection (Eyepacs)** veri seti kullanılmıştır. Veri seti yaklaşık 35.000 adet retina fundus görüntüsünden oluşmakta olup[viii], her bir görüntü 0 ile 4 arasında değişen beş farklı hastalık evresi ile etiketlenmiştir.

Veri setinin ilk incelemesinde, sınıflar arasında ciddi bir dengesizlik olduğu gözlemlenmiştir. Özellikle “No DR (0)” sınıfının veri setinde baskın olduğu, ileri evre sınıfların (3 ve 4) ise oldukça sınırlı sayıda örnek içerdiği belirlenmiştir. Bu durum, modelin çoğunluk sınıfına eğilim göstermesine ve az temsil edilen sınıflarda düşük performans sergilemesine neden olabilecek kritik bir problemdir.

Bu kapsamda veri seti üzerinde aşağıdaki ön işleme adımları uygulanmıştır:

- Tüm görüntülerin RGB formatına dönüştürülmesi
- Görüntü boyutlarının model mimarisine uygun olacak şekilde yeniden ölçeklendirilmesi (224×224 ve 384×384)
- ImageNet veri setine ait ortalama ve standart sapma değerleri ile normalize edilmesi
- Stratified 5-Fold Cross Validation yöntemi ile veri bölünmesi

Bu sayede hem veri dağılımı korunmuş hem de modelin genelleme yeteneği artırılmıştır.



Şekil 1 Veri seti sınıf dağılım grafiği

Şekil 1’de görüldüğü üzere veri setinde ciddi bir sınıf dengesizliği bulunmaktadır. Bu durum, sonraki aşamalarda uygulanacak veri artırma ve kayıp fonksiyonu stratejilerinin temel motivasyonunu oluşturmuştur.

2.2 Veri Artırma ve Sınıf Dengesizliğinin Giderilmesi

Veri setindeki dengesizlik problemini çözmek ve modelin genelleme yeteneğini artırmak amacıyla çok aşamalı bir veri artırma (data augmentation) stratejisi uygulanmıştır. İlk aşamada temel augmentasyon teknikleri kullanılmıştır:

- Random horizontal flip ,Random rotation ,Color jitter

Ancak bu yöntemlerin tek başına yeterli olmadığı görülmüş ve retina görüntülerine özgü daha gelişmiş teknikler pipeline’a dahil edilmiştir:


- **CLAHE (Contrast Limited Adaptive Histogram Equalization):** Retina damar yapılarının daha belirgin hale getirilmesi
- **RandomGamma:** Işık değişimlerine karşı modelin dayanıklılığının artırılması
- **RandomResizedCrop:** Retina diskini koruyarak farklı ölçeklerde öğrenme sağlanması
- **GaussNoise:** Sensör gürültüsüne karşı robustluk kazandırılması

Bunun yanı sıra sınıf dengesizliği ile mücadele etmek amacıyla:

- **Class-Balanced Focal Loss**
- **WeightedRandomSampler**
- **Mixup ($\alpha=0.2$)**

yöntemleri entegre edilmiştir.

Bu yaklaşımlar sayesinde modelin özellikle nadir görülen sınıflarda daha dengeli öğrenme gerçekleştirdiği gözlemlenmiştir.



Şekil 2. Augmentation sonrası sınıf dağılımı

Şekil 2 incelendiğinde veri artırma sonrası sınıf dağılımının daha dengeli hale geldiği ve model eğitimi için daha uygun bir yapı oluşturulduğu görülmektedir.

2.3 Model Geliştirme ve Deneysel Aşamalar

Model geliştirme süreci üç temel aşamada gerçekleştirilmiştir:

2.3.1 Aşama 1 – Klasik CNN Tabanlı Yaklaşım

İlk aşamada literatürde yaygın olarak kullanılan klasik CNN mimarileri [ix] ile başlangıç çalışmaları yapılmıştır: ResNet50 ,DenseNet121 ,DenseNet169 ,Xception ,InceptionV3. Bu modeller, problemi anlamak ve baseline performans elde etmek amacıyla eğitilmiştir. Elde edilen sonuçlar:


- QWK: 0.60 – 0.68
- Accuracy: ~0.78

Bu sonuçlar, klasik CNN mimarilerinin temel bir performans sunduğunu ancak problemin karmaşıklığı için yetersiz kaldığını göstermiştir.

2.3.2 Aşama 2 – Transformer[x] ve EfficientNet[xi] Yaklaşımı

ikinci aşamada daha modern mimarilere geçilmiştir: Swin Transformer Tiny[xii] ,EfficientNet-B3[xiii]

Bu modeller ile daha yüksek temsil gücü elde edilmiş ve performans: **QWK $\approx$ 0.69** seviyesine yükselmiştir. Bu aşamada ayrıca ilk ensemble yaklaşımı denenmiş ve: **QWK $\approx$ 0.72** elde edilmiştir.




Şekil 3 İlk Ensemble Confusion Matrix (Swin-Tiny ve Efficient-B3)

2.3.3 Aşama 3 – Gelişmiş Pipeline ve Modern Mimariler

Projenin en kritik aşamasında hem veri işleme pipeline'ı hem de model mimarileri önemli ölçüde geliştirilmiştir. Kullanılan modeller: ConvNeXt-Small[xiv],EfficientNetV2-S,Swin-Tiny,EfficientNet-B3 (geliştirilmiş pipeline ile)


Eğitim ayarları: Optimizer: AdamW ,Learning rate: 1e-4 ,Epoch: 30 ,Cosine Annealing scheduler ,Early stopping (patience=5)

Diabetic Retinopathy Detection System Pipeline



Şekil 4 Model pipeline akış diyagramı

Şekil 4 bu aşamada geliştirilen pipeline, veri artırma, loss fonksiyonu ve model mimarisini entegre eden bütüncül bir yapı sunmakta olduğunu da daha net göstermektedir.



Şekil 5 Model gelişim sürecini + performans artışını gösteren profesyonel grafik

Şekil 5. Model geliştirme süreci boyunca elde edilen QWK performans değerlerinin karşılaştırılması. Klasik CNN modellerinden başlanarak transformer tabanlı mimarilere ve gelişmiş pipeline'a geçiş ile performansta belirgin bir artış sağlandığı görülmektedir. Özellikle ensemble yaklaşımı ile en yüksek performans elde edilmiştir.

2.4 Ensemble Model ve Optimizasyon Süreci


Tekil modellerin performansını daha da artırmak amacıyla çoklu model birleştirme (ensemble) yöntemi uygulanmıştır. Model çıktıları softmax olasılıkları üzerinden birleştirilmiş, ardından expected value hesaplanarak ordinal threshold optimizasyonu uygulanmıştır. Bu yaklaşım, problemin ordinal doğasına uygun olarak tasarlanmış ve performansı önemli ölçüde artırmıştır.

2.5 Model Performans Değerlendirme

Model performansı aşağıdaki metrikler ile değerlendirilmiştir:

- Accuracy
- Balanced Accuracy
- Macro F1 Score
- Weighted F1 Score
- Quadratic Weighted Kappa (QWK)


Elde edilen sonuçlar: **QWK: 0.93**,Accuracy: 0.90,Balanced Accuracy: 0.78,Macro F1: 0.76



Şekil 6 Confusion Matrix ve Normalize Confusion Matrix

Şekil 6. Ensemble modelin doğrulama veri seti üzerindeki karışıklık matrisi. Modelin özellikle düşük evre diyabetik retinopati sınıflarında yüksek doğruluk sağladığı, ancak ileri evre sınıflar arasında kısmi karışmalar olduğu gözlemlenmektedir.

Ve tabi normalize edilmiş karışıklık matrisi. Sınıflar bazında modelin doğruluk oranları incelendiğinde, özellikle düşük evre sınıflarda yüksek performans elde edildiği görülmektedir.




Şekil 7 ROC Curve ve Precision-Recall Curve

Şekil 7. ROC eğrisi. Modelin farklı eşik değerlerinde doğru pozitif ve yanlış pozitif oranları arasındaki ilişkiyi göstermektedir. Ayrıca Precision-Recall eğrisi. Modelin özellikle dengesiz veri setlerinde sınıflandırma başarısını değerlendirmek için kullanılmıştır.

2.6 Eğitim Süreci Analizi

Modelin eğitim süreci boyunca performans değişimi detaylı olarak incelenmiştir.



Şekil 8 Accuracy ve Loss Grafiği

Şekil 8’de modelin eğitim sürecine ait doğruluk ve kayıp değerlerinin epoch’lara göre değişimi birlikte incelendiğinde, modelin kararlı ve dengeli bir öğrenme süreci gerçekleştirdiği görülmektedir. Eğitim doğruluğunun epoch’lar ilerledikçe istikrarlı bir şekilde arttığı ve doğrulama doğruluğunun eğitim performansını yakından takip ettiği gözlemlenmiştir. Benzer şekilde, hem eğitim hem de doğrulama kayıp değerlerinin düzenli olarak azaldığı ve belirli bir noktadan sonra dengelenerek plato yaptığı görülmektedir. Bu durum, modelin öğrenme sürecini başarıyla tamamladığını ve aşırı öğrenme (overfitting) probleminin etkili bir şekilde kontrol altına alındığını göstermektedir. Ayrıca, erken durdurma (early stopping) mekanizmasının kullanılması sayesinde modelin en iyi performansı elde ettiği epoch civarında eğitim sonlandırılmış, böylece gereksiz öğrenme ve performans bozulmasının önüne geçilmiştir. Bu bulgular, geliştirilen modelin yalnızca eğitim verisi üzerinde değil, aynı zamanda görülmemiş veriler üzerinde de yüksek genelleme yeteneğine sahip olduğunu ortaya koymaktadır.

3.proje yönetimi

3.1 İş-Zaman Çizelgesi

İP No	İş Paketlerinin Adı ve Hedefleri	Kim(ler) Tarafından Gerçekleştirileceği	Zaman Aralığı	Başarı Ölçütü ve Katkısı	Durum
1	Literatür taraması ve problem tanımı (diyabetik retinopati analizi)	Zahra Esparghami, Mohammadparsa Malek, Ozan Duru	01 Mayıs – 20 Mayıs 2025	Problem alanının belirlenmesi ve proje kapsamının oluşturulması	Tamamlandı
2	Veri setinin incelenmesi ve veri analizi (Eyepacs dataset)	Zahra Esparghami	21 Mayıs – 10 Haziran 2025	Veri yapısının ve sınıf dağılımının analiz edilmesi	Tamamlandı
3	Veri ön işleme (resize, normalize, veri temizleme)	Zahra Esparghami, Mohammadparsa Malek	11 Haziran – 30 Haziran 2025	Verilerin model girişine uygun hale getirilmesi	Tamamlandı
4	Veri artırma tekniklerinin uygulanması (augmentation, CLAHE vb.)	Ozan Duru, Mohammadparsa Malek	01 Temmuz – 20 Temmuz 2025	Sınıf dengesizliğinin azaltılması ve genellemenin artırılması	Tamamlandı
5	Klasik CNN modellerinin eğitimi (ResNet, DenseNet, Inception)	Zahra Esparghami, Mohammadparsa Malek	21 Temmuz – 20 Ağustos 2025	Baseline performansın elde edilmesi	Tamamlandı
6	Transformer ve EfficientNet modellerinin eğitimi	Ozan Duru, Mohammadparsa Malek	21 Ağustos – 25 Eylül 2025	Model performansının artırılması	Tamamlandı
7	Gelişmiş eğitim pipeline'ının kurulması (loss, optimizer, scheduler)	Zahra Esparghami, Ozan Duru	26 Eylül – 25 Ekim 2025	Stabil ve optimize eğitim sürecinin oluşturulması	Tamamlandı
8	Ensemble model geliştirme ve ağırlık optimizasyonu	Zahra Esparghami, Mohammadparsa Malek	26 Ekim – 20 Kasım 2025	Farklı modellerin birleştirilmesi ile performans artırımı	Tamamlandı
9	Model performans analizi (confusion matrix, ROC, PR, accuracy-loss)	Mohammadparsa Malek, Ozan Duru, Zahra Esparghami	21 Kasım – 15 Aralık 2025	Modelin detaylı değerlendirilmesi	Tamamlandı
10	Hata analizi ve model iyileştirme çalışmaları	Ozan Duru, Zahra Esparghami	16 Aralık 2025 – 31 Ocak 2026	Modelin zayıf yönlerinin iyileştirilmesi	Tamamlandı
11	Sonuçların yorumlanması ve rapor yazımı	Mohammadparsa Malek	01 Şubat – 15 Mart 2026	Akademik raporun hazırlanması	Tamamlandı
12	Nihai düzenleme ve teslim süreci	Ozan Duru, Mohammadparsa Malek, Zahra Esparghami	16 Mart – 31 Mart 2026	TÜBİTAK formatına uygun final teslim	Devam Ediyor

3.2 Risk Yönetimi

İP No	En Önemli Riskler	Risk Yönetimi (B Planı)	Risk Durumu
1	Veri setinde sınıf dengesizliği	Data augmentation, class weight ve focal loss kullanımı	Gerçekleşti ancak kontrol altına alındı
2	Modelin düşük performans göstermesi	Farklı model mimarilerinin denenmesi	Gerçekleşti
3	Overfitting problemi	Early stopping, dropout ve veri artırma	Gerçekleşti ancak kontrol altına alındı
4	Yüksek GPU ihtiyacı	Google Colab ve batch size optimizasyonu	Gerçekleşti
5	Model eğitiminin uzun sürmesi	Learning rate scheduler ve optimize eğitim	Gerçekleşmedi
6	Sınıflar arası karışıklık	Ensemble model ve threshold optimizasyonu	Kısmen gerçekleşti

3.3 Araştırma Olanakları

Kuruluştaki Bulunan Altyapı/Ekipman Türü	Çalışmada Kullanım Amacı	Kullanılma Durumu
Google Colab (GPU destekli ortam)	Model eğitimi ve deneylerin gerçekleştirilmesi	Kullanıldı
Python (PyTorch, NumPy, Pandas)	Model geliştirme ve veri işleme	Kullanıldı
OpenCV ve görüntü işleme araçları	Veri ön işleme ve augmentasyon	Kullanıldı
Kaggle Eyepacs veri seti	Retina görüntü veri kaynağı	Kullanıldı
Jupyter Notebook / VS Code	Kod geliştirme ve analiz	Kullanıldı

3.4 Yaygın Etki

Yaygın Etki Türleri	Beklenen Çıktı, Sonuç ve Etkiler	Tamamlanma Durumu
Bilimsel / Akademik	Derin öğrenme tabanlı DR sınıflandırma sistemi ve akademik rapor	Devam ediyor
Teknolojik	Yapay zeka tabanlı karar destek sistemi geliştirilmesi	Tamamlandı
Sağlık	Diyabetik retinopatinin erken teşhisine katkı	Kısmen tamamlandı
Eğitim	Yapay zeka ve medikal görüntüleme alanında deneyim kazanımı	Tamamlandı

4. Materyal ve Metot

4.1 Kullanılan Veri Seti ve Materyaller

Bu çalışmada diyabetik retinopati evrelerinin sınıflandırılması amacıyla Kaggle[xv] platformunda yer alan Diabetic Retinopathy Detection (Eyepacs) veri seti kullanılmıştır. Veri seti yaklaşık 35.000 adet retina fundus görüntüsünden oluşmakta olup, her görüntü 0 (No DR) ile 4 (Proliferatif DR) arasında değişen beş farklı sınıfa ait etiketler içermektedir.

Çalışmada kullanılan veri seti, sınıf dağılımı korunacak şekilde eğitim (train) ve doğrulama (validation) olarak ikiye ayrılmıştır. Eğitim veri seti 28.100 görüntüden, doğrulama veri seti ise 7.026 görüntüden oluşmaktadır. Ayrıca Kaggle platformu tarafından sağlanan ve etiket bilgisi içermeyen ayrı bir test veri seti, modelin gerçek dünya performansını değerlendirmek amacıyla kullanılmıştır.

4.1.1 Veri Seti Dağılım Tablosu

Veri Seti Bölümü	Görüntü Sayısı	Oran	Açıklama
Eğitim (Train)	28100	%80	Modelin öğrenmesi için kullanılan veri seti
Doğrulama (Validation)	7026	%20	Model performansının izlenmesi ve hiperparametre ayarı
Test (Kaggle)	Etiketsiz	-	Modelin gerçek veri üzerindeki performansını değerlendirmek için kullanılmıştır
Toplam	35126	%100	Eğitim ve doğrulama veri setlerinin toplamı

4.1.2 Sınıf Dağılım Tablosu

Sınıf	Train	Validation	Açıklama
0 (No DR)	20648	5162	Sağlıklı retina
1 (Mild)	1954	489	Hafif DR
2 (Moderate)	4234	1058	Orta seviye DR
3 (Severe)	698	175	İleri DR
4 (Proliferative)	566	142	En ileri evre DR

Veri seti incelendiğinde sınıflar arasında belirgin bir dengesizlik olduğu gözlemlenmiştir. Özellikle düşük evre sınıfların veri setinde daha fazla temsil edildiği, ileri evre sınıfların ise sınırlı sayıda örnek içerdiği görülmektedir. Bu durum model eğitimi sürecinde dikkate alınmış ve veri artırma ile sınıf dengeleme teknikleri uygulanmıştır.

Veri ön işleme aşamasında tüm görüntüler model girişine uygun olacak şekilde yeniden boyutlandırılmış (224×224 ve 384×384), normalize edilmiş ve RGB formatında işlenmiştir. Bu sayede farklı model mimarileri ile uyumlu bir veri yapısı elde edilmiştir.

Çalışmada kullanılan temel materyaller aşağıda sunulmuştur:

- Python programlama dili
- PyTorch derin öğrenme kütüphanesi
- Google Colab GPU destekli çalışma ortamı
- OpenCV ve veri artırma (augmentation) araçları
- Kaggle Eyepacs veri seti

4.2 Yöntem (Model Geliştirme Süreci)

Bu çalışmada diyabetik retinopati sınıflandırma problemi, aşamalı bir model geliştirme yaklaşımı ile ele alınmıştır. Süreç boyunca farklı derin öğrenme mimarileri test edilmiş ve performans karşılaştırmaları yapılmıştır. Model geliştirme süreci üç temel aşamadan oluşmaktadır: klasik CNN modelleri, modern mimariler ve gelişmiş pipeline ile ensemble yaklaşımı.

4.3 MODEL PERFORMANS KARŞILAŞTIRMA TABLOSU

Model	Aşama	Accuracy	Balanced Accuracy	Macro F1	Weighted F1	QWK	Açıklama
ResNet50	Aşama 1(CNN)	0.76	0.60	0.58	0.74	0.62	Temel baseline model
DenseNet121	Aşama 1(CNN)	0.77	0.62	0.60	0.75	0.64	Daha iyi feature extraction
DenseNet169	Aşama 1(CNN)	0.78	0.63	0.61	0.76	0.66	Derin yapı avantajı
InceptionV3	Aşama 1(CNN)	0.77	0.61	0.59	0.75	0.63	Multi-scale öğrenme
Xception	Aşama 1(CNN)	0.78	0.62	0.60	0.76	0.65	Depthwise convolution avantajı
EfficientNet-B3	Aşama 2	0.82	0.68	0.66	0.80	0.69	Parametre verimli model
Swin-Tiny	Aşama 2	0.83	0.69	0.67	0.81	0.70	Transformer tabanlı öğrenme
Swin-T + EffNet Ensemble	Aşama 2	0.89	0.71	0.69	0.83	0.72	İlk ensemble denemesi
EfficientNet-B3 (geliştirilmiş)	Aşama 3	0.88	0.74	0.72	0.86	0.84	Augmentation + tuning
Swin-Tiny (geliştirilmiş)	Aşama 3	0.89	0.75	0.73	0.87	0.86	Pipeline iyileştirme
EfficientNetV2-S	Aşama 3	0.90	0.77	0.75	0.88	0.90	Modern mimari
ConvNeXt-Small	Aşama 3	0.91	0.78	0.76	0.89	0.91	En güçlü tekil model
Final Ensemble Model	Final	0.90	0.78	0.76	0.88	0.93	En yüksek performans

4.4 Eğitim Pipeline ve Kullanılan Teknikler

Model eğitim sürecinde performansı artırmak amacıyla çeşitli veri işleme ve optimizasyon teknikleri uygulanmıştır. Veri artırma aşamasında CLAHE, gamma düzeltme, gürültü ekleme ve rastgele kırpma gibi yöntemler kullanılmıştır. Bu sayede modelin farklı veri dağılımlarına karşı daha dayanıklı hale gelmesi sağlanmıştır. Sınıf dengesizliği problemini çözmek amacıyla class-balanced focal loss ve weighted sampling yöntemleri kullanılmıştır. Ayrıca modelin aşırı öğrenmesini engellemek için early stopping mekanizması uygulanmıştır. Model eğitimi sırasında AdamW optimizasyon algoritması kullanılmış ve öğrenme oranı scheduler ile dinamik olarak ayarlanmıştır.

4.5 Ensemble Yöntemi

Model performansını artırmak amacıyla birden fazla modelin çıktıları birleştirilmiştir. Bu kapsamda ConvNeXt-Small, EfficientNetV2-S, EfficientNet-B3 ve Swin-Tiny modelleri belirli ağırlıklar ile birleştirilmiştir. Elde edilen softmax çıktıları üzerinden ortalama alınmış ve nihai tahminler elde edilmiştir. Bu yaklaşım, tekil modellere kıyasla daha yüksek doğruluk ve daha dengeli sınıflandırma performansı sağlamıştır.

5.Sonuç

Bu çalışma kapsamında, diyabetik retinopati evrelerinin retina fundus görüntüleri üzerinden yüksek doğrulukla sınıflandırılmasına yönelik çok aşamalı ve bütüncül bir derin öğrenme pipeline'ı geliştirilmiştir. Model geliştirme sürecinde başlangıç olarak ResNet50, DenseNet ve Inception tabanlı klasik CNN mimarileri ile temel bir performans analizi gerçekleştirilmiş, ardından daha yüksek temsil gücüne sahip Swin Transformer ve EfficientNet-B3 modelleri ile özellik çıkarım kapasitesi artırılmıştır. Nihai aşamada ise ConvNeXt-Small, EfficientNetV2-S, EfficientNet-B3 ve Swin-Tiny modellerinin son katman çıktıları (softmax olasılık dağılımları) ağırlıklı olarak birleştirilmiş ve elde edilen çıktılar üzerinde beklenen değer (expected value) ve eşik (threshold) optimizasyonu uygulanarak ordinal sınıflandırma yapısı güçlendirilmiştir. Ayrıca eğitim sürecinde kullanılan gelişmiş veri artırma teknikleri, class-balanced loss fonksiyonları ve örnekleme stratejileri sayesinde veri setindeki sınıf dengesizliği etkili bir şekilde azaltılmıştır. Bu çoklu model ve çok aşamalı eğitim yaklaşımı sonucunda, geliştirilen sistemin doğrulama veri seti üzerinde yüksek doğruluk ve yüksek Quadratic Weighted Kappa (QWK) değeri elde ettiği gözlemlenmiş, ensemble yönteminin tekil modellere kıyasla daha dengeli ve güvenilir sonuçlar sağladığı ortaya konmuştur. Elde edilen bulgular, önerilen pipeline'ın diyabetik retinopati gibi sınıflar arası geçişlerin belirsiz olduğu medikal görüntüleme problemlerinde etkili bir çözüm sunduğunu ve klinik karar destek sistemlerine entegre edilebilecek potansiyele sahip olduğunu göstermektedir.

5.1 FINAL ENSEMBLE MODEL MİMARİ VE BİRLEŞTİRME TABLOSU

Model	Kullanılan Katman / Çıkış Noktası	Fine-Tuning Stratejisi	Ensemble Ağırlığı	Modelin Rolü
ConvNeXt-Small	Global Average Pooling + Fully Connected + Softmax	Son bloklar ve classifier katmanı eğitildi	%50	Ana model (yüksek doğruluk ve stabil tahmin)
EfficientNetV2-S	MBConv Blocks + Global Pooling + Softmax	Üst katmanlar fine-tune edildi	%30	Dengeli öğrenme ve genelleme
EfficientNet-B3	MBConv + Fully Connected + Softmax	Son katmanlar yeniden eğitildi	%15	Stabilite ve düşük varyans
Swin-Tiny	Transformer Encoder Blocks + Classification Head	transformer blokları fine-tune edildi	%5	Global feature katkısı
Ensemble Yöntemi	Softmax olasılıklarının ağırlıklı ortalaması	Expected value + threshold	-	Nihai tahmin üretimi

Tablo 5.1de sunulan final ensemble modeli, farklı mimarilerin son katman çıktılarının ağırlıklı olarak birleştirilmesi ile oluşturulmuştur. ConvNeXt-Small modelinin ana ağırlığı taşıdığı bu yapı, EfficientNet ve Swin Transformer tabanlı modeller ile desteklenmiştir. Modellerden elde edilen softmax olasılıkları üzerinde ağırlıklı ortalama alınmış ve beklenen değer ile eşik optimizasyonu uygulanarak nihai sınıflandırma gerçekleştirilmiştir. Bu çoklu model yaklaşımı, tekil modellere kıyasla daha yüksek doğruluk ve daha dengeli bir performans elde edilmesini sağlamıştır.

5.2 FINAL ENSEMBLE MODEL PERFORMANS TABLOSU

Metrik	Değer	Açıklama
Accuracy	0.90	Genel doğruluk oranı
Balanced Accuracy	0.78	Sınıf dengesizliği dikkate alınarak hesaplanan doğruluk
Macro F1-Score	0.76	Tüm sınıflar için eşit ağırlıklı F1 skoru
Weighted F1-Score	0.88	Sınıf dağılımına göre ağırlıklı F1 skoru
Quadratic Weighted Kappa (QWK)	0.93	Sınıflar arası ordinal ilişkiyi dikkate alan metrik
Precision (Macro)	0.77	Ortalama kesinlik değeri
Recall (Macro)	0.75	Ortalama duyarlılık değeri

Tablo 5.2 de, geliştirilen final ensemble modeline ait performans metrikleri sunulmuştur. Elde edilen sonuçlar incelendiğinde, modelin özellikle Quadratic Weighted Kappa (QWK) metriğinde yüksek bir performans sergilediği görülmektedir. Bu durum, modelin diyabetik retinopati evreleri arasındaki ordinal ilişkileri başarılı bir şekilde öğrenebildiğini göstermektedir. Ayrıca accuracy ve F1-score değerleri, modelin dengeli ve güvenilir bir sınıflandırma performansı sunduğunu ortaya koymaktadır.

6.Çıktılar (Yayınlar,sunumlar v.b.)

Çıktı Türü	Detaylar	Durum	Katkısı
Sunum	"Derin Öğrenme Tabanlı Diyabetik Retinopati Sınıflandırma Sistemi" başlıklı teknik sunum (model pipeline, ensemble yaklaşımı ve performans analizlerini içeren)	Yapılacak	Projenin akademik ortamda tanıtılması ve yapay zeka tabanlı medikal görüntüleme çalışmalarına katkı sağlanması
Test Sonuçları (Bilimsel Çıktı)	Final ensemble modeline ait performans metrikleri (Accuracy, Balanced Accuracy, Macro/Weighted F1, QWK), Confusion Matrix, ROC ve Precision-Recall eğrileri	Tamamlandı	Geliştirilen modelin bilimsel olarak değerlendirilmesini sağlayan deneysel çıktılar
Model Pipeline	Veri ön işleme, augmentation, model eğitimi ve ensemble aşamalarını içeren bütüncül derin öğrenme pipeline'ı	Tamamlandı	Medikal görüntüleme problemleri için uygulanabilir bir yapay zeka çözüm mimarisi sunar
Yazılım (Jupyter Notebook Altyapısı)	PyTorch tabanlı, modüler ve yeniden kullanılabilir Jupyter Notebook kod altyapısı (veri yükleme, eğitim, validasyon, metrik hesaplama ve görselleştirme modülleri)	Tamamlandı	Araştırmacılar için güçlü ve genişletilebilir bir deney ortamı sağlar
Model Dosyaları	Eğitilmiş model ağırlıkları (.pth formatında) ve ensemble model çıktıları	Tamamlandı	Modelin yeniden kullanılmasını ve farklı veri setleri üzerinde test edilmesini sağlar
Görsel Çıktılar	Model performansını gösteren grafikler (accuracy-loss, confusion matrix, ROC, PR curve, model karşılaştırma grafikleri)	Tamamlandı	Model performansının görsel ve anlaşılır şekilde sunulmasını sağlar
Kod Altyapısı ve Pipeline Sistemi	Veri artırma, class-balanced loss, scheduler, optimizer ve ensemble mekanizmasını içeren tam eğitim pipeline'ı	Tamamlandı	Gelecek projelerde doğrudan kullanılabilecek ileri düzey yapay zeka altyapısı sağlar
Gelecek Yayın Potansiyeli	Çalışmanın akademik makale veya konferans bildirisine dönüştürülmesi planlanmaktadır	Planlanıyor	Yapay zeka ve medikal görüntüleme alanına bilimsel katkı sağlanması

7.Proje ile ilgili harcama kalemleri hakkında ayrıntılı bilgi

Bütçe Türü	Talep Edilen Bütçe Miktarı	Talep Gerekçesi	Gerçekleşme
Sarf Malzeme	0 TL	Yoktur	Yoktur
Makina/Teçhizat(Demirbaş)	0 TL	Yoktur	Yoktur
Hizmet Alımı	3496.74 TL	- 2999.94 TL: ChatGPT Plus abonelik hizmeti (6 ay boyunca model geliştirme, kod optimizasyonu ve analiz süreçlerinde aktif olarak kullanılmıştır)	
	3496.74 TL	- 496.80 TL: Google Colab Pro abonelik hizmeti (GPU erişimi sağlanarak model eğitimi ve deneyler gerçekleştirilmiştir)	
Ulaşım	0 TL	Yoktur	Yoktur
TOPLAM	3496.74 TL		3496.74 TL

8.Kaynakçalar

- [i] Gulshan, V., Peng, L., Coram, M., et al. (2016). *Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs*. JAMA, 316(22), 2402–2410.
- [ii] Pratt, H., Coenen, F., Broadbent, D. M., Harding, S. P., & Zheng, Y. (2016). *Convolutional Neural Networks for Diabetic Retinopathy*. Procedia Computer Science, 90, 200–205.
- [iii] Voets, M., Möllersen, K., & Bongo, L. A. (2019). *Replication Study: Development and Validation of a Deep Learning Algorithm for Detection of Diabetic Retinopathy in Retinal Fundus Photographs*. PLOS ONE, 14(6).
- [iv] Lam, C., Yu, C., Huang, L., & Rubin, D. (2018). *Retinal Lesion Detection with Deep Learning Using Image Patches*. Investigative Ophthalmology & Visual Science.
- [v] Tan, M., & Le, Q. (2019). *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. ICML.
- [vi] Tan, M., & Le, Q. (2021). *EfficientNetV2: Smaller Models and Faster Training*. ICML.
- [vii] Liu, Z., Mao, H., Wu, C.-Y., et al. (2021). *A ConvNet for the 2020s (ConvNeXt)*. CVPR.
- [viii] Liu, Z., Lin, Y., Cao, Y., et al. (2021). *Swin Transformer: Hierarchical Vision Transformer using Shifted Windows*. ICCV.
- [ix] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep Residual Learning for Image Recognition*. CVPR.
- [x] Huang, G., Liu, Z., Van Der Maaten, L., & Weinberger, K. (2017). *Densely Connected Convolutional Networks*. CVPR.
- [xi] Chollet, F. (2017). *Xception: Deep Learning with Depthwise Separable Convolutions*. CVPR.
- [xii] Szegedy, C., Vanhoucke, V., Ioffe, S., et al. (2016). *Rethinking the Inception Architecture for Computer Vision*. CVPR.

13. [xiii] Kingma, D. P., & Ba, J. (2015). *Adam: A Method for Stochastic Optimization*. ICLR.
14. [xiv] Lin, T.-Y., Goyal, P., Girshick, R., et al. (2017). *Focal Loss for Dense Object Detection*. ICCV.
15. [xv] Kaggle. (2015). Diabetic Retinopathy Detection Dataset.
<https://www.kaggle.com/c/diabetic-retinopathy-detection>

PROJE YÜRÜTÜCÜSÜNÜN ADI – SOYADI - İMZA	DANIŞMANIN ADI – SOYADI - İMZA
ZAHRA ESPARGHAMI	PROF. DR. ÖZGÜR KORAY ŞAHİNGÖZ
	

Tarih :31.03.2026